Übungsblatt 5

Aufgabe 1 (9 Punkte)

Dass wir gut mit DataFrames umgehen können, ist absolut zentral. Und da hilft nur Übung, Übung, Übung. Deshalb geht es hier nun in die nächste Runde Datenanalyse...

- (a) Im GitHub-repository unter data befindet sich die Datei fish.csv. Ladet den Datensatz in Julia als DataFrame ein.
- (b) Macht Euch mit der Struktur des Datensatzes vertraut. Gebt eine Tabelle mit dem Gewicht der Fische je Spezies aus (für die Funktion mean braucht ihr wieder das Modul Statistics).
- (c) Überlegt euch kurz, wozu wir CategoricalArrays.jl brauchen.
- (d) Die Spalte : Spezies soll nun kategorische Variablen beinhalten; die levels sollen nach Anzahl an Observationen geordnet sein (Tipp: Erstellt euch einen Array mit sortierten Spezies.).
- (e) Erstellt eine lineare Regression, um die Laenge_diag anhand von Laenge_vert vorherzusagen. Bestimmt auch die Kennzahl \mathbb{R}^2 für die Regression.
- (f) select: Gebt alle Spalten bis auf die letzten beiden aus. Lasst Euch darüber hinaus alle Spalten anzeigen, die den Buchstaben "a" enthalten (Tipp: names).

Aufgabe 2 (5 + 2 Punkte)

In dieser Aufgabe geht es um Korrelationen. Wenn noch gar kein Vorwissen über Korrelation vorhanden ist, bitte etwas in das Thema einlesen.

- (a) Arbeitet mit dem Datensatz aus Aufgabe 1 weiter. Berechnet mithilfe des cor() Befehls die Korrelation zwischen Laenge_vert und Gewicht. Erscheint ein Zusammenhang dieser Variablen sinnvoll?
- (b) Plottet die Spalten Laenge_vert und Gewicht gegeneinander ab und fügt eine Ausgleichsgerade hinzu. Wie gut passt die Ausgleichsgerade zu den Daten? (Tipp: predict)
- (c) Zusatzaufgabe: Erstellt eine quadratische Regression (wieder mit hinzugefügtem Linienplot) für die vorherige Teilaufgabe.

Aufgabe 3 (2 Punkte, Zusatzaufgabe)

Überlege Dir, wie man Folgendes elegant hinbekommt:

Für x = [[0, 1], [0, 1, 2], usw.] hätten wir gerne einen Operator \oplus , sodass gilt $exp\oplus(x) = [[1.0, 2.71828...], [1.0, 2.71828..., 7.38905...]$ usw.]

Viel Erfolg!